

Previsão de Aprovação de Crédito

com Machine Learning

Disciplina de Inteligência Artificial — Professor Munif

Unicesumar 2026

Matheus Felipe Campioto Catenacci — RA: 22014137-2

André Felipe Ferrari de Azevedo — RA: 22120196-2

■ Machine Learning

■ German Credit Data

■ Python / Scikit-learn

1. Resumo do Projeto

A concessão de crédito é uma das atividades mais críticas do setor financeiro. Conceder crédito a um cliente de alto risco pode gerar prejuízos significativos, enquanto negar crédito a um bom pagador representa perda de receita. A inteligência artificial permite automatizar e tornar esse processo mais preciso e justo.

Problema

Como prever se um cliente será um bom ou mau pagador com base em suas características financeiras e pessoais?

Hipótese

É possível construir modelos de IA capazes de classificar o risco de crédito de um cliente com acurácia superior a 70%, utilizando características como idade, valor do crédito, duração do empréstimo e histórico financeiro.

2. Dataset

Atributo	Valor
Nome	German Credit Data
Origem	UCI Machine Learning Repository (via OpenML)
Registros	1.000 clientes
Distribuição	700 bons pagadores / 300 maus pagadores
Treino / Teste	80% (800 amostras) / 20% (200 amostras)
Split	Estratificado — random_state=42

Atributos Principais

- Age — Idade
- Housing — Tipo de moradia
- Saving accounts — Poupança
- Checking account — Conta corrente
- Credit amount — Valor do crédito
- Duration — Duração em meses
- Purpose — Finalidade do crédito
- Risk — Variável alvo (good / bad)

Preparação dos Dados

- Conversão de variáveis categóricas com LabelEncoder
- Normalização com StandardScaler
- Remoção de valores nulos

3. Métodos de IA Utilizados

Parte 1 — Random Forest (Supervisionado / Preditivo)

Random Forest é um método de ensemble que cria múltiplas árvores de decisão independentes e combina suas previsões por votação majoritária. É robusto contra overfitting e lida bem com dados desbalanceados.

Parâmetro	Valor
n_estimators	100
random_state	42

Parte 2 — SVM — Support Vector Machine (Supervisionado / Preditivo)

SVM é um algoritmo supervisionado que encontra o hiperplano de maior margem que separa as classes. Com o kernel RBF (Radial Basis Function), captura relações não-lineares nos dados. Ambos os modelos foram treinados nas mesmas condições — mesmo split, mesmo scaler, mesmo random_state —

garantindo uma comparação justa.

Parâmetro	Valor
kernel	rbf
C	1.0
gamma	scale
random_state	42

Parte 3 — K-Means Clustering (Não Supervisionado / Descritivo)

K-Means é um algoritmo de agrupamento não supervisionado que segmenta os clientes em grupos com características similares, sem usar a variável alvo. O Método do Cotovelo determinou K=3 como número ideal de clusters.

4. Avaliação dos Modelos

Comparação: Random Forest vs SVM

Métrica	Random Forest	SVM (RBF)	Vencedor
Acurácia	73.00%	73.50%	SVM (+0.5%)
F1-Score	0.7165	0.7082	Random Forest
Precisão	0.7134	0.7142	SVM (+0.0008)
Revocação	0.7300	0.7350	SVM (+0.005)

Os dois modelos apresentaram desempenho equivalente. O SVM teve acurácia levemente superior (0.5%), enquanto o Random Forest obteve F1-Score maior. Com apenas 200 amostras de teste, essa diferença não é estatisticamente significativa.

O **Random Forest é preferível para produção** por ser interpretável — é possível identificar quais features mais influenciaram cada decisão, o que é fundamental em crédito, onde a justificativa de negativas é exigida regulatoriamente.

Random Forest — Métricas por Classe

Classe	Precisão	Revocação	F1-Score	Suporte
Mau Pagador	0.57	0.42	0.48	60
Bom Pagador	0.78	0.86	0.82	140

K-Means — Perfil dos Clusters (K=3)

Cluster	Maus	Bons	Idade Média	Crédito Médio	Duração	Perfil
---------	------	------	-------------	---------------	---------	--------

0	127	199	30 anos	R\$ 2.335	17 meses	Jovens, créditos pequenos
1	48	286	39 anos	R\$ 2.088	16 meses	Menor risco
2	65	75	37 anos	R\$ 7.784	39 meses	Maior risco proporcional

5. Gráficos Gerados

Arquivo	Descrição
distribuicao_risco.png	Distribuição da variável alvo
analise_exploratoria.png	Análise de idade e crédito por risco
random_forest_features.png	Importância das features — Random Forest
curva_acuracia_rf.png	Acurácia por número de árvores
matrizes_confusao.png	Matrizes de confusão — RF e SVM lado a lado
comparacao_rf_svm.png	Comparação de métricas RF vs SVM
metodo_cotovelo.png	Escolha do K ideal para K-Means
kmeans_resultados.png	Clusters visualizados com PCA

6. Conclusão

O projeto aplicou três modelos de IA ao problema de risco de crédito:

- Random Forest e SVM (supervisionados, preditivos) foram comparados diretamente pelas mesmas métricas. Ambos atingiram ~73% de acurácia, superando a hipótese inicial de 70%. As features mais relevantes foram Duration, Credit amount e Age.
- K-Means (não supervisionado, descritivo) identificou 3 perfis distintos de clientes. O Cluster 2 representa o maior risco proporcional — créditos altos (R\$7.784 em média) e longa duração (39 meses), com quase 1 mau pagador para cada bom pagador.

A combinação dos três modelos oferece uma solução completa: **predição automatizada (RF/SVM) + segmentação estratégica (K-Means)**.

7. Como Executar

1. Acesse o Google Colab (colab.research.google.com)
2. Faça upload do arquivo trabalho_ia_credito_att.ipynb
3. Execute todas as células em ordem (Ctrl+F9)
4. Os gráficos e modelos serão gerados automaticamente
5. O dataset é carregado automaticamente via OpenML — não é necessário upload do CSV

8. Modelos Treinados

Arquivo	Descrição
modelo_random_forest.pkl	Modelo Random Forest treinado
modelo_svm.pkl	Modelo SVM (RBF) treinado
modelo_kmeans.pkl	Modelo K-Means treinado
scaler.pkl	StandardScaler ajustado ao treino

9. Estrutura do Repositório

trabalho_ia_credito_att.ipynb	– Notebook principal
german_credit_data.csv	– Dataset (referência local)
modelo_random_forest.pkl	– Modelo treinado
modelo_svm.pkl	– Modelo treinado
modelo_kmeans.pkl	– Modelo treinado
scaler.pkl	– Scaler
comparacao_rf_svm.png	– Gráfico comparativo RF vs SVM
matrizes_confusao.png	– Matrizes de confusão
distribuicao_risco.png	– Distribuição da variável alvo
analise_exploratoria.png	– Análise exploratória
random_forest_features.png	– Importância das features
curva_acuracia_rf.png	– Curva de acurácia RF
metodo_cotovelo.png	– Método do cotovelo K-Means
kmeans_resultados.png	– Resultados K-Means
README.md	– Este arquivo